

# Otimização de Rotas com Lucro Baseada em Algoritmos de Colônia de Formigas

Luan Medrado Moreira, Lucas Rego Da Silva  
Centro Universitário Euro Americano (Unieuro), Brasília, Brasil  
Email: luan61449@unieuro.com.com, lucas60899 @unieuro.com.com

Orientador

Dr. Aldo Henrique Dias Mendes  
Centro Universitário Euro Americano (Unieuro), Brasília, Brasil  
Email: aldoh.ti@gmail.com

## Resumo

Este artigo apresenta uma aplicação do algoritmo de Colônia de Formigas (Ant Colony Optimization, ACO) para a otimização de rotas visando maximizar lucros em um cenário de transporte de combustíveis entre cidades brasileiras. A abordagem utiliza dados de compra e venda de combustíveis para calcular diferenças de preços como heurísticas. A implementação segue tendências recentes da literatura, adaptando estratégias do ACO para problemas de roteamento e maximização de lucros. Os resultados obtidos demonstram a eficácia do método proposto e destacam oportunidades para aprimoramento, como a inclusão de restrições temporais e dinâmicas no modelo.

## Abstract

This article presents an application of the Ant Colony Optimization (ACO) algorithm for optimizing routes to maximize profits in a fuel transport scenario between Brazilian cities. The approach uses fuel purchase and sales data to calculate price differences as heuristics. The implementation follows recent trends in the literature, adapting ACO strategies to routing and profit maximization problems. The results obtained demonstrate the effectiveness of the proposed method and highlight opportunities for improvement, such as the inclusion of temporal and dynamic constraints in the model.

## 1.1. Contextualização

A otimização de rotas é um problema clássico com impacto direto em operações logísticas. Algoritmos metaheurísticos, como o ACO, têm se destacado em aplicações como o roteamento de veículos capacitados (CVRP) e problemas com múltiplas restrições, incluindo janelas de tempo e múltiplos depósitos, devido à sua robustez na busca por soluções eficientes em problemas complexos (Jinsi Cai et al., 2022).

No contexto do transporte de combustíveis, identificar rotas que maximizem lucros baseando-se nas diferenças de preços entre cidades oferece um novo campo de estudo. Estratégias híbridas de ACO, que combinam heurísticas locais e métodos como busca de vizinhança variável, mostraram-se eficazes na literatura para lidar com problemas de otimização onde múltiplas variáveis influenciam as decisões de roteamento (Petr Stodola, 2020).

## **1.2. Objetivo**

O objetivo deste trabalho é implementar uma solução baseada no ACO para maximizar lucros no transporte de combustíveis entre cidades, utilizando diferenças de preços de compra e venda como heurísticas e feromônios como guia.

## **2. Fundamentação Teórica**

### **2.1. Algoritmos de Colônia de Formigas**

O ACO é um método bioinspirado que simula o comportamento de formigas ao depositar feromônios em caminhos durante a busca por comida. Este método tem sido amplamente aplicado em problemas de roteamento devido à sua capacidade de explorar iterativamente o espaço de soluções. Estudos recentes adaptaram o ACO para diversos problemas, como roteamento com janelas de tempo (Ashima Gupta & Sanjay Saini, 2017) e roteamento de veículos elétricos, onde limitações de autonomia e pontos de recarga devem ser considerados (Michalis Mavrouniotis et al., 2018).

### **2.2. Aplicação no Roteamento de Veículos**

O ACO é frequentemente combinado com estratégias híbridas para melhorar a eficiência e evitar convergência prematura. Por exemplo, a estratégia de "redução dinâmica de espaço" reduz o espaço de busca ao longo das iterações, permitindo que o algoritmo explore soluções mais refinadas (Jinsi Cai et al., 2022).

Além disso, operações de mutação e resfriamento simulado ajudam a diversificar a busca e melhorar a precisão das soluções, como no caso de problemas com múltiplos depósitos ou restrições temporais (Petr Stodola, 2020).

## **Implementação**

### **3.1. Descrição do Problema**

O problema modelado consiste em encontrar rotas lucrativas entre cidades brasileiras, considerando diferenças de preços de compra e venda de combustíveis. O modelo utiliza um grafo onde os nós representam cidades e as arestas, as diferenças de preços.

### **3.2. Algoritmo Desenvolvido**

O algoritmo implementado adapta o ACO tradicional ao problema, calculando a heurística com base na diferença entre os preços médios de venda de uma cidade e de compra em outra. A solução incorpora ideias como:

Evaporação de Feromônios: Para evitar acúmulo excessivo em rotas subótimas.

Cálculo Heurístico Baseado em Lucros: Similar a abordagens híbridas que consideram múltiplas métricas de decisão (Petr Stodola, 2020).

### **3.3. Funcionamento do Algoritmo e Cálculo**

O algoritmo de Colônia de Formigas (ACO) utilizado neste estudo segue uma abordagem iterativa e bioinspirada, replicando o comportamento coletivo das formigas para encontrar soluções otimizadas. A seguir, detalhamos cada passo do processo e os cálculos envolvidos:

### **3.3.1. Inicialização dos Parâmetros**

- Entrada: Lista de cidades, dados de compra e venda de combustíveis, número de formigas, número de iterações, taxa de evaporação dos feromônios, e os parâmetros de influência dos feromônios ( $\alpha$ ) e da heurística ( $\beta$ ).
- Feromônios: Inicializados com valores iguais em todas as arestas (rotas possíveis), representando um estado neutro onde nenhuma rota é preferida inicialmente.
- Heurística: Calculada com base na diferença entre o preço médio de venda de combustíveis em uma cidade (origem) e o preço médio de compra em outra cidade (destino).

### **3.3.1.2 Cálculo da Heurística**

A heurística para cada par de cidades é dada pelo cálculo do lucro, caso a diferença seja negativa, a heurística é zerada, pois rotas com prejuízo não são interessantes.

### **3.3.1.3 Construção de Rotas pelas Formigas**

Para cada iteração, cada formiga inicia em uma cidade e constrói sua rota iterativamente, seguindo os passos:

#### **3.3.1.3.1. Seleção da Próxima Cidade:**

A probabilidade de uma formiga se mover de uma cidade para uma cidade é calculada com base no feromônio e na heurística:

**A. Onde:**

- Peso que controla a influência dos feromônios.
- Peso que controla a influência da heurística.
- O denominador normaliza as probabilidades considerando todas as cidades ainda disponíveis.

### **3.3.2. Escolha Estocástica:**

A próxima cidade é escolhida com base nas probabilidades calculadas. Cidades com maior lucro potencial ou maior depósito de feromônio têm maior probabilidade de serem escolhidas.

### **3.3.3. Atualização da Rota e Cálculo do Lucro:**

A diferença de preços entre as cidades visitadas é acumulada para calcular o lucro total da rota construída pela formiga:

#### **3.3.4. Condição de Parada:**

O processo continua até que todas as cidades tenham sido visitadas ou não existam mais cidades com heurística positiva.

#### **3.3.5. Atualização de Feromônios**

Após todas as formigas concluírem suas rotas, os feromônios são atualizados para reforçar as rotas mais lucrativas

##### **3.3.5.1. Evaporação de Feromônios:**

Uma fração dos feromônios em todas as arestas é reduzida para evitar que soluções subótimas dominem onde é a taxa de evaporação.

##### **3.3.5.2. Depósito de Feromônios:**

As formigas que obtiveram maior lucro depositam feromônio adicional nas arestas que compõem suas rotas.

Rotas mais lucrativas recebem uma quantidade proporcional de feromônio, incentivando outras formigas a explorá-las nas próximas iterações.

#### **3.3.6. Critério de Convergência**

O algoritmo termina após um número predefinido de iterações. A melhor rota encontrada durante todas as iterações é armazenada como a solução final.

#### **3.3.7 Resumo do Funcionamento**

- A. As formigas constroem rotas baseadas em feromônios e heurística, priorizando rotas lucrativas.
- B. A atualização de feromônios reforça as rotas mais lucrativas, enquanto outras são gradualmente descartadas.
- C. Após várias iterações, o algoritmo converge para uma solução que representa a melhor rota para maximização de lucros.

Esse processo iterativo combina exploração (ao buscar novas rotas) e intensificação (ao reforçar as melhores rotas), garantindo um equilíbrio entre qualidade da solução e eficiência computacional.

### **Resultados e Discussão**

#### **4.1 Base de dados e Configuração do Problema**

A base de dados utilizada neste estudo foi extraída do portal Dados Abertos do Governo Federal (), que disponibiliza uma série histórica de preços de combustíveis automotivos em diversas cidades brasileiras. Essa base fornece informações detalhadas sobre os preços médios de venda e compra de combustíveis, como gasolina, etanol e diesel, em diferentes períodos.

#### **4.1.2 Estrutura da Base de Dados**

A base é composta pelos seguintes campos principais:

- Município: Nome da cidade onde os preços foram registrados.
- Produto: Tipo de combustível (ex.: Gasolina Comum, Diesel S10).
- Preço de Compra: Valor médio que os postos de combustível pagam ao fornecedor pelo produto.
- Preço de Venda: Valor médio cobrado dos consumidores finais.
- Data de Referência: Período em que os preços foram coletados.

#### **4.1.3 Seleção das Cidades e Configuração do Problema**

Neste estudo, o usuário selecionou dez cidades específicas para compor o problema, além de definir uma cidade inicial a partir da qual as rotas seriam construídas. Essa seleção é baseada em critérios como relevância econômica das cidades, disponibilidade de dados na base, ou simplesmente escolha arbitrária para simular cenários reais.

##### **4.1.4 Cidades Selecionadas:**

- Brasília (cidade inicial)
- Vinhedo
- Curitiba
- São Paulo
- Guarujá
- Vitória da Conquista
- Belo Horizonte
- Nova Iguaçu
- Teresina
- Palmas

A cidade inicial escolhida foi Brasília, e a partir dela, o algoritmo iniciou o processo de construção de rotas considerando as demais cidades como possíveis destinos.

#### **4.1.5 Preparação da Base para o Algoritmo**

##### **4.1.5.1. Carregamento e Filtragem:**

Os dados foram carregados de um arquivo CSV contendo a série histórica. Durante o processamento, as informações foram filtradas para manter apenas as cidades e o combustível relevante para o estudo (no caso, Gasolina Comum).

##### **4.1.5.2. Preenchimento de Dados Faltantes:**

Em casos em que faltavam registros de compra ou venda para uma cidade específica, os valores foram preenchidos com base na média dos dados disponíveis para aquela cidade.

#### **4.1.5.3. Atribuição de Valores Aleatórios:**

Para enriquecer o cenário e simular variações reais no mercado, foi utilizada uma distribuição normal para atribuir valores aleatórios de compra a cada cidade, garantindo um comportamento mais dinâmico no problema. Esses valores respeitaram uma média () e desvio padrão (), com um limite inferior.

#### **4.1.5.4. Matriz de Diferenças de Preço (Heurística):**

A partir dos valores de compra e venda, foi criada uma matriz que calcula a diferença entre o preço de venda em uma cidade e o preço de compra em outra. Essa matriz serviu como a base para a heurística do algoritmo, priorizando rotas que maximizam os lucros:

Essa estrutura permite identificar oportunidades de lucro ao transportar combustíveis entre cidades.

#### **4.1.6 Por que Escolher Esta Base?**

A escolha dessa base de dados se justifica por sua abrangência e confiabilidade, fornecendo dados reais que permitem modelar cenários práticos de transporte e maximização de lucros. Além disso, a granularidade das informações (preços de compra e venda para cada cidade) oferece a oportunidade de explorar a aplicação do ACO em problemas reais do mercado de combustíveis no Brasil.

Essa configuração inicial permitiu que o algoritmo trabalhasse com dados representativos, simulando a operação de transporte de combustíveis entre cidades e maximizando os lucros com base nas diferenças de preços.

### **4.2 Resultados**

Os experimentos demonstraram que o algoritmo desenvolvido é capaz de identificar rotas lucrativas entre as cidades analisadas. A melhor solução encontrada apresenta um percurso eficiente, conectando cidades estrategicamente escolhidas para maximizar os lucros com base nas diferenças de preços de compra e venda de combustíveis.

O lucro esperado para a melhor rota encontrada foi significativamente maior em comparação às soluções aleatórias, evidenciando a eficácia do modelo. O desempenho do algoritmo também se mostrou consistente ao longo de múltiplas execuções, com variações mínimas nos resultados.

Na imagem apresentada a seguir, gerada no Power BI, é possível visualizar os resultados da análise ao iniciar a rota pela cidade de Brasília, com um lucro esperado de R\$ 6,11. O relatório inclui gráficos comparativos que destacam os valores de compra e venda de combustíveis em cada cidade, além de alguns cards. Esses elementos permitem uma compreensão clara dos fatores que influenciam a otimização das rotas e a maximização dos lucros.

## A. Imagem de resultados



Figure 1: Relatório gerado no Power BI mostrando os gráficos comparativos de valores de compra e venda de combustíveis por cidade e a tabela com a amostra de dados utilizada para calcular o lucro esperado ao iniciar a rota por Brasília.

## 4.3 Discussão

Os resultados confirmam a eficácia do ACO para maximizar lucros em problemas de roteamento com base em preços de compra e venda. Estratégias como redução dinâmica de espaço (Jinsi Cai et al., 2022). Poderiam ser incorporadas ao algoritmo para reduzir a chance de convergência em mínimos locais.

## Conclusão

### 5.1 Resumo dos Resultados

Este estudo demonstrou que o ACO pode ser efetivamente adaptado para problemas de maximização de lucros no transporte de mercadorias, utilizando as diferenças de preços de compra e venda como métrica principal para a definição de rotas. O algoritmo se mostrou capaz de explorar o espaço de soluções considerando tanto os custos operacionais quanto o potencial de lucro, aproveitando o comportamento emergente de feromônios para priorizar trajetos com maior rentabilidade.

Além disso, os resultados evidenciaram que o uso de uma heurística baseada em lucros proporciona uma abordagem flexível e adaptável para diferentes cenários logísticos. Mesmo em problemas sem restrições explícitas, como janelas de tempo ou capacidade de veículos, o ACO

foi capaz de encontrar soluções próximas ao ideal, equilibrando a exploração de novas rotas e a intensificação de rotas lucrativas previamente identificadas.

Esse sucesso destaca o potencial do ACO para aplicações práticas, como a otimização de transportes em mercados dinâmicos, onde os preços variam e a seleção de rotas lucrativas é essencial para a competitividade econômica. A abordagem também se mostra promissora para ser estendida com a inclusão de múltiplas restrições e objetivos, como eficiência energética e sustentabilidade.

## **5.2 Contribuições e Limitações**

Este estudo oferece contribuições significativas ao demonstrar a aplicabilidade do algoritmo de Otimização por Colônia de Formigas (ACO) em problemas de transporte e maximização de lucros, destacando a utilização de diferenças de preços como métrica de decisão. No entanto, também apresenta limitações que devem ser consideradas para futuras pesquisas.

### **5.3 Contribuições**

#### **5.3.1 Adaptação do ACO para Maximização de Lucros:**

O estudo adapta o ACO para um contexto diferente dos tradicionais problemas de roteamento, utilizando diferenças de preços entre cidades como base para a heurística. Isso destaca o potencial do ACO para solucionar problemas relacionados a arbitragem de preços em mercados reais, como o transporte de combustíveis.

#### **5.3.2 Modelo Baseado em Dados Reais:**

A utilização da base de dados do portal Dados Abertos do Governo Federal agrega confiabilidade e realismo ao modelo, permitindo que o problema seja analisado com base em cenários práticos.

A seleção manual de cidades pelo usuário confere flexibilidade para adaptar o modelo a diferentes contextos regionais ou de mercado.

#### **5.3.3 Exploração de Rotas Lucrativas:**

O algoritmo identifica rotas que maximizam o lucro esperado, equilibrando a exploração de novas soluções com a intensificação de caminhos promissores. Essa abordagem pode ser aplicada a outros cenários de transporte ou mercados que envolvam diferenças regionais de preços.

### **5.4 Limitações**

#### **5.4.1 Simplificação dos Dados:**

Apesar de utilizar dados reais, o modelo simplifica o problema ao assumir que os valores de compra e venda são constantes e representam médias confiáveis. Em cenários reais, os preços podem variar diariamente e estar sujeitos a fatores externos, como sazonalidade ou custos logísticos adicionais.

#### **5.4.2 Ausência de Restrições Logísticas:**



O modelo não considera limitações práticas, como capacidade de transporte, custos de combustível, ou tempo de deslocamento. Esses fatores podem impactar significativamente a viabilidade das rotas propostas.

#### **5.4.3 Dependência dos Parâmetros do ACO:**

O desempenho do algoritmo depende fortemente da escolha dos parâmetros ( $\alpha$ ,  $\beta$ ,  $\rho$ , número de formigas e iterações). Pequenas variações nesses valores podem alterar os resultados, exigindo uma análise mais aprofundada de sensibilidade.

#### **5.4.4 Escalabilidade:**

Embora eficiente para o conjunto de 10 cidades, o algoritmo pode enfrentar desafios de desempenho à medida que o número de cidades aumenta, devido ao crescimento exponencial do espaço de busca.

### **5.5 Recomendações para Trabalhos Futuros**

#### **5.5.1 Incorporação de Restrições Reais:**

Adicionar restrições de capacidade, custos de transporte e tempo de viagem para tornar o modelo mais representativo de cenários reais.

#### **5.5.2 Avaliação de Sensibilidade dos Parâmetros:**

Realizar estudos de sensibilidade para identificar combinações ideais de parâmetros, garantindo a robustez do algoritmo.

#### **5.5.3 Escalabilidade para Grandes Redes:**

Investigar técnicas de otimização híbridas, como a combinação do ACO com algoritmos genéticos ou resfriamento simulado, para melhorar a eficiência em problemas maiores.

#### **5.5.4 Integração de Dados Dinâmicos:**

Explorar a utilização de dados em tempo real, como preços atualizados e condições logísticas, para aumentar a aplicabilidade prática do modelo.

Assim, este estudo não apenas reforça o potencial do ACO para aplicações de transporte e maximização de lucros, mas também identifica áreas de melhoria que podem guiar futuras implementações mais complexas e robustas.

## **GLOSSÁRIO**

### **1 - ACO (Ant Colony Optimization)**

Um algoritmo inspirado no comportamento das colônias de formigas para encontrar rotas eficientes, utilizando conceitos como feromônios e heurísticas para guiar as soluções.

### **2 - Feromônio**

Uma variável no algoritmo ACO que simula o rastro químico deixado pelas formigas, utilizado para influenciar escolhas futuras com base na atratividade de caminhos anteriores.

### 3 - Heurística

Critério utilizado para guiar as formigas na escolha de rotas, baseado em informações específicas do problema, como diferenças de preços ou distâncias.

### 4 - Variáveis ajustáveis no algoritmo, como:

$\alpha$

$\alpha$ : Peso dado aos feromônios.

$\beta$

$\beta$ : Peso dado à heurística.

$\rho$

$\rho$ : Taxa de evaporação do feromônio.

### 5 - Base de Dados

Conjunto de informações organizadas, como o utilizado neste estudo para registrar os preços de compra e venda de combustíveis em diferentes cidades.

### 6 - Algoritmo Bioinspirado

Tipo de algoritmo baseado em comportamentos naturais observados em sistemas biológicos, como colônias de formigas, enxames de abelhas ou evolução genética.

### 7 - Metaheurística

Abordagem de otimização de alto nível que busca soluções aproximadas para problemas complexos, geralmente combinando técnicas de exploração e intensificação. Exemplos incluem ACO, Algoritmos Genéticos e Busca Tabu.

## REFERÊNCIAS

. Jinsi Cai, Peng Wang, Siqing Sun & Huachao Dong. (2022). Dynamic Space Reduction Ant Colony Optimization for Capacitated Vehicle Routing Problems. Springer.

. Hongguang Wu, Yuelin Gao, Wanting Wang & Ziyu Zhang. (2023). A Hybrid Ant Colony Algorithm Based on Multiple Strategies for Vehicle Routing Problem with Time Windows. Springer.

. Petr Stodola. (2020). Hybrid Ant Colony Optimization Algorithm Applied to the Multi-Depot Vehicle Routing Problem. Springer.

- . Ashima Gupta & Sanjay Saini. (2017). An Enhanced Ant Colony Optimization Algorithm for Vehicle Routing Problem with Time Windows. IEEE Xplore.
- . Michalis Mavrovouniotis, Georgios Ellinas & Marios Polycarpou. (2018). Ant Colony Optimization for the Electric Vehicle Routing Problem. IEEE Xplore.
- . Base de Dados: <https://dados.gov.br/dados/conjuntos-dados/serie-historica-de-precos-de-combustiveis-e-de-glp>